


1. **Источник данных сайт iNaturalist и свободный источник(гугл изображения).**
Выборка состоит из набора изображений и их аннотаций, поделённых на 3 класса
blooming_hogweed (1993 изображения), faded_hogweed(1861 изображения),
thickets_hogweed(2590 изображения).


Аннотации сделаны с помощью labelImg в формате pascal voc.



Пример кода аннотаций:

```
<?xml version='1.0' encoding='utf-8'?>
<annotation>
  <folder>train</folder>
  <filename>blooming_0000.jpg</filename>
  <source>
    <database>Unknown</database>
  </source>
  <size>
    <width>1024</width>
    <height>1024</height>
    <depth>3</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>blooming_sosnovsky</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>9</xmin>
      <ymin>11</ymin>
      <xmax>974</xmax>
      <ymax>1016</ymax>
    </bndbox>
  </object>
</annotation>
```

2. На данный момент сделана аннотирована вся bloom_hogweed часть датасета, большая часть faded_hogweed и небольшая часть thickets_hogweed. Вот текущие графики по нормализованным данным:



Всего боксов: 9105

Статистика для ширины:

Мин: 0.0205

Макс: 0.9995

Среднее: 0.3041

Медиана: 0.1958

Стандартное отклонение: 0.2723

Статистика для высоты:

Мин: 0.0240

Макс: 0.9995

Среднее: 0.3912

Медиана: 0.2989

Стандартное отклонение: 0.2678

На данный момент ещё не была сделана полная аннотация и полные выводы о состоянии датасета.

3. Оценка качества разметки.

На текущем этапе полностью размечен класс `blooming_hogweed`, большая часть изображений класса `faded_hogweed` и небольшая часть класса `thickets_hogweed`. В связи с неполной разметкой итоговая оценка качества датасета носит предварительный характер.

По состоянию на данный момент:

- Общее количество размеченных объектов составляет 9155 bounding boxes, что является достаточным объёмом данных для обучения современных моделей детекции объектов.
- Анализ распределения размеров объектов показывает наличие как крупных, так и мелких экземпляров борщевика:
 - средняя нормализованная ширина объекта — 0.304;
 - средняя нормализованная высота объекта — 0.391;
 - диапазон размеров близок к полному диапазону изображения (от 0.02 до 0.999).
- Наличие объектов различных масштабов положительно влияет на способность модели обобщать данные и обнаруживать растения на разных расстояниях.
- Предварительный анализ не выявил критических ошибок в структуре аннотаций (отрицательные координаты, выход боксов за границы изображения и др.).
- Однако окончательная оценка качества разметки может быть проведена только после завершения аннотирования всех классов и дополнительной проверки согласованности границ объектов.

Предварительный вывод: текущая разметка имеет удовлетворительное качество и достаточный объём для начала экспериментов по обучению модели, однако для получения объективных метрик требуется завершение разметки всего датасета и проведение финального аудита аннотаций.

4. Описанием алгоритма формирования выборки для решения задачи и стратегии валидации:

Подготовка данных выполняется в несколько этапов:

1. Загрузка изображений и соответствующих .xml.
2. Динамическая аугментация и нормализация.
3. Приведение изображения к нужному размеру, поворот зеркально по горизонтали с вероятностью 50%.
4. Нормализация изображения (деление на 255.0) для правильной подачи в модель - переводит в диапазон [0.0, 1.0].

Стратегия разделения данных:

Для обучения и оценки модели планируется использовать следующее разделение:

- обучающая выборка (Train) - 60%;
- валидационная выборка (Validation) - 25%;
- тестовая выборка (Test) - 15%.

Разделение датасета выполняется на уровне изображений. Перед разбиением осуществляется случайное перемешивание (random shuffle) с фиксированным значением random seed, что обеспечивает воспроизводимость экспериментов и снижает риск смещения выборки.

Поскольку в одной изображении может присутствовать несколько объектов разных классов, дополнительно рассматривается подход стратифицированного разбиения по наличию классов (multi-label stratified split). Данный метод позволяет более равномерно распределить изображения с разными комбинациями классов между обучающей, валидационной и тестовой выборками.

Во время обучения дополнительно применяется перемешивание обучающей выборки перед каждой эпохой, что снижает риск переобучения и улучшает сходимость модели.